



MÁSTER EN DATA SCIENCE Y BUSINESS ANALYTICS

DESARROLLO Y EVALUACIÓN DE SISTEMAS DE PREDICCIÓN DE RIESGO DE DIABETES MEDIANTE APRENDIZAJE AUTOMÁTICO

TFM elaborado por: Adrián Benito Varela

Tutor/a de TFM: Juan Manuel Moreno Lamparero

- Madrid 21/09/2026 -

Agradecimientos

Primeramente, me gustaría agradecer a mi tutor Juan Manuel Moreno Lamparero por su apoyo y orientación durante todo el curso. Siempre se ha mostrado como una persona cercana y disponible, dispuestos a aportar ejemplos y sugerencias para la realización del proyecto.

A la escuela IMF por dotarme de las herramientas y los conocimientos necesarios para el desarrollo de principio a fin de este proyecto. Y por facilitarme el acceso a un entorno de aprendizaje competitivo y adaptable para poder expresar todo el material.

También me gustaría reconocer el aporte de la comunidad científica y los organismos institucionales que facilitaron el acceso libre a la información en la que se basa este TFM, así, mi agradecimiento a los CDC (Centers for Disease Control and Prevention) por la recopilación de los datos de la encuesta BRFSS y su posterior difusión, y al autor del dataset Teboul, A por su aporte a la comunidad con su publicación.

Por último, me gustaría agradecer a mis amigos y en especial mi familia por el apoyo continuo durante estos meses, siempre han estado ahí y han sido capaces de reportar grandes consejos y apoyo emocional, el cual ha sido vital para completar este proyecto en tiempo y forma.

Índice de contenidos

- 1. Resumen (Abstract)**
- 2. Introducción y antecedentes**
- 3. Objetivos del proyecto**
 - 3.1. Objetivo general**
 - 3.2. Objetivos específicos**
- 4. Material y métodos**
 - 4.1. Conjunto de datos**
 - 4.2. Entorno y librerías**
 - 4.3. Preprocesamiento de datos**
 - 4.4. Algoritmos de Machine Learning**
 - 4.5. Métricas de evaluación**
- 5. Resultados**
 - 5.1. Adquisición de fuentes de datos**
 - 5.2. Descripción de la fuente de datos**
 - 5.3. Análisis exploratorio de los datos (EDA)**
 - 5.4. Preprocesado de datos**
 - 5.5. Selección de variables**
 - 5.6. Partición en Train y Test**
 - 5.7. Aplicación de modelos de aprendizaje automático**
 - 5.8. Evaluación y validación de modelos de aprendizaje automático**
 - 5.9. Comparativa de resultados**
- 6. Conclusiones**
- 7. Referencias bibliográficas**
- 8. Notas**
- 9. Anexo**

1. Resumen

La diabetes representa uno de los principales riesgos de salud pública a nivel mundial en el s. XXI. En este proyecto, se pretende plantear y desarrollar una serie de modelos de aprendizaje automático enfocados en el aprendizaje supervisado, que permitan realizar predicciones de riesgo, tomando datos del dataset *Diabetes Health Indicators*, basado en los datos limpios, autoreportados, de la encuesta *Behavioral Risk Factor Surveillance System (BRFSS)*. Con tal motivo, se realizó un proyecto de machine learning en Python, siguiendo la metodología aprendida durante el desarrollo del curso.

Los datos se dividieron con la clásica proporción 80/20 para su estudio, y se aplicaron métodos de validación cruzada sobre los datos de entrenamiento para aquellos modelos que se comportaron peor de lo esperado.

Entre los algoritmos que se estudiaron, se incluyeron la Regresión Logística y el Gradient Boosting, seguidos de los modelos que finalmente hubo que optimizar para mitigar el desbalanceo de clases, como K-Nearest Neighbors, Random Forest y Redes Neuronales. El modelo que mejor se comportó para los datos analizados fue Gradiente Boosting, el cual mostró una capacidad de discriminación general de 0,81 y una sensibilidad para la clase minoritaria de 0,76.

Según los análisis de importancia previamente realizados, las variables que se identificaron como principales predictoras de la diabetes fueron: Índice de Masa Corporal (BMI por sus siglas en inglés), Edad (Age) y Salud General Percibida (GenHlth).

Tras los resultados obtenidos, se demostró que las herramientas de machine learning, bien podrían emplearse para realizar cribados poblacionales con datos poco invasivos y de fácil acceso como pudieran ser los obtenidos a través de encuestas o cribados express en centros de atención primaria.

Palabras clave: Aprendizajes automático, Diabetes, Machine Learning, Python, Poco Invasivos, Atención primaria

Abstract

Diabetes represents one of the major public health risks worldwide in the 21st century. This project aims to propose and develop a series of supervised machine learning models to predict diabetes risk using data from the Diabetes Health Indicators dataset, which is based on clean, self-reported data from the Behavioral Risk Factor Surveillance System (BRFSS) survey. To this end, a machine learning project was carried out in Python following the methodology learned during the course.

The data was split using the conventional 80/20 ratio for analysis, and cross-validation techniques were applied to the training set for models that performed below expectations.

The algorithms studied included Logistic Regression and Gradient Boosting, along with models that ultimately required optimization to mitigate class imbalance, such as K-Nearest Neighbors, Random Forest, and Neural Networks. The best-performing model for the analyzed dataset was Gradient Boosting, which achieved an overall discriminative capacity (AUC-ROC) of 0.81 and a sensitivity (Recall) for the minority class of 0.76.

Based on prior feature importance analyses, the primary predictors identified for diabetes were Body Mass Index (BMI), Age, and General Health Perception (GenHlth).

These results demonstrate that machine learning tools could effectively be leveraged for population-level screening using non-invasive, accessible data, such as information gathered through self-reported surveys or rapid screenings in primary care settings.

Keywords: Machine Learning, Diabetes, Python, Non-invasive, Primary Care


2. Introducción y antecedentes

La diabetes es una enfermedad mundialmente extendida y representa uno de los principales desafíos sanitarios del s. XXI. El carácter asintomático de la enfermedad en sus primeras etapas genera que una buena parte de población conviva con la enfermedad durante un periodo más o menos largo de su vida, sin un diagnóstico médico de la misma. En un contexto como este, es importante la aplicación de algoritmos de aprendizaje automático y modelos de predicción que nos ayuden a trabajar sobre los datos, de manera no invasiva, como podrían ser los datos obtenidos en encuestas de población, para realizar cribados, capaces de clasificar los perfiles de mayor riesgo en la población y así, facilitar el diagnóstico médico por parte de los especialistas, al atacar directamente los casos más significativos.

Para contextualizar, la diabetes se manifiesta cuando la glucosa en sangre (azúcar), se encuentra de forma continuada en niveles por encima de los habituales. La glucosa, es uno de los principales encargados de aportarle energía al cuerpo, y aunque el propio cuerpo puede producirla de manera endógena, lo hace en cantidades moderadas. La mayor parte del aporte glucémico que necesita nuestro organismo proviene de aquellos alimentos que consumimos.

Figura 1

Glucosa en sangre.



Comparación visual de los niveles de glucosa normales y elevados en el torrente sanguíneo. Imagen tomada del National Institute of Diabetes and Digestive and Kidney Diseases.

Para que la glucosa pueda ser utilizada por el cuerpo como fuente de energía, es indispensable un componente esencial, la insulina, una hormona producida por el páncreas que actúa como una especie

de llave las células. La insulina facilita el transporte de la glucosa en sangre hasta el interior celular, para suministrarles el aporte energético que necesitan. Del mismo modo, aquella glucosa sobrante que no puede ser utilizada por las células, se almacena como fuente de energía tanto en el hígado como en los músculos, un proceso conocido como glucogénesis, otro mecanismo de reserva que también se encuentra regulado gracias a la insulina.

Existen, por tanto, dos principales causas de la diabetes, en el primero de los casos, conocido como **Diabetes Tipo I**, los individuos sufren una especie de reacción autoinmune, por la cual, su propio cuerpo ataca e intenta destruir las células del páncreas que se encargan de la producción de insulina, por tanto, son incapaces de producir suficiente insulina, o directamente no producen, derivando en una constante acumulación de glucosa en sangre. Es por esto por lo que dichos individuos dependen en su día a día de inyectarse de manera externa una serie de dosis de insulina para mantener los niveles normales en sangre. Este tipo de diabetes se manifiesta generalmente en niños y adultos jóvenes. La segunda causa, es lo que comúnmente conoceríamos como **Diabetes Tipo II**, este tipo de diabetes se produce generalmente en personas ya adultas (habitualmente por encima de los 40), debido principalmente a unos malos hábitos como el sedentarismo o el sobrepeso, los cuales contribuyen a que las células de los músculos, la grasa o el hígado se vayan haciendo resistentes a la insulina y no respondan de forma eficiente a la misma. Esto obliga al cuerpo a sobreproducir insulina para compensar la resistencia de las células, sin embargo, según el problema se va agravando, el páncreas no es capaz de producir suficiente insulina para compensar la resistencia generada en las células del organismo, generando el mismo problema que veíamos al comienzo, una acumulación excesiva de glucosa en el torrente sanguíneo.

Conociendo las causas, podemos observar cómo existen dos tipos de diabetes con un componente común, la acumulación de glucosa en sangre, pero con disparadores muy diferentes. Mientras que una se produce por causas “naturales” o predisposición genética, la otra, se ve fuertemente influenciada por unos malos hábitos desarrollados en el tiempo. Conocer estos detalles, podría sernos de gran ayuda a la hora de tratar de buscar características comunes en individuos con diabetes.

3. Objetivos del proyecto

Una vez conocidas las referencias a la diabetes y analizado la importancia de la detección de la enfermedad en etapas tempranas, en este capítulo se tratarán de establecer las metas analíticas del proyecto.

Para ello, se define el objetivo general del proyecto, centrado en dar una respuesta al problema planteado, acompañado de una serie de objetivos específicos que detallan la metodología empleada para llegar al mismo.

3.1. Objetivo general

El objetivo general del proyecto será desarrollar y evaluar un conjunto de modelos de aprendizaje automático supervisado (ya que contaremos con datos etiquetados previamente), basados en diferentes criterios, para tratar de predecir el riesgo de diabetes implícito en un conjunto de individuos ya conocidos. Para ello, contaremos con una serie de variables sanitarias, demográficas, de estilo de vida, etc. (obtenidas de un dataset de Kaggle, que recopila los datos de la encuesta **BRFSS**¹: *Behavioral Risk Factor Surveillance System* o Sistema de Vigilancia de Factores de Riesgo en el Comportamiento). Priorizaremos minimizar los falsos negativos y maximizar los positivos reales, ya que, son métricas ampliamente utilizadas en el ámbito clínico.

3.2. Objetivos específicos

Como objetivos específicos del proyecto, detallar las principales metodologías empleadas para alcanzar el objetivo principal del proyecto con la mayor exactitud y precisión posibles:

- Preprocesamiento de los datos → Realizar un Análisis Exploratorio de los Datos (EDA) para tratar de identificar patrones en las variables recogidas en la encuesta del BRFSS y tratar el desequilibrio de clases mediante **binarización**².
- Modelado y entrenamiento → Implementar una variedad de algoritmos supervisados, aplicando técnicas de escalado y validación cruzada para maximizar el rendimiento de cada modelo.
- Evaluación y comparativa → Evaluar los modelos en función de unas métricas críticas para su comparativa (Sensibilidad, precisión, AUC-ROC, F1...). Priorizando la sensibilidad o *recall* y el área bajo la curva **ROC**³.

- Explicabilidad y conclusiones → Valorar la explicabilidad de los resultados obtenidos, como de fieles a la realidad pueden considerarse, si respetan los criterios clínicos y extraer conclusiones que permitan justificar la utilidad del modelo seleccionado como herramienta no invasiva de cribado poblacional para detección de diabetes.

4. Material y métodos

En este capítulo se definen los materiales, tecnologías y metodología aplicadas en el proceso de desarrollo del proyecto de aprendizaje automático. Para ello, se detallan las principales características del conjunto de datos empleado, el flujo de trabajo diseñado para abordar el problema y el tratamiento de los datos: ingeniería de variables, entrenamiento de los modelos, criterio y evaluación de los resultados obtenidos.

4.1. Conjunto de datos

Para la realización del proyecto se tomó el “*Diabetes Health Indicators Dataset (BRFSS/CDC)*”, un conjunto de datos que recoge en 22 variables numéricas, las respuestas de 253.680 ciudadanos anónimos de los EE. UU. a una serie de preguntas relacionadas con su salud (física y mental), sus hábitos alimenticios, condiciones socioeconómicas, etc.

Posteriormente se les preguntaba si estaban diagnosticados con alguna enfermedad, en este caso, la diabetes. La base de datos recoge así la frecuencia y porcentaje de casos que puede observarse en la tabla 1.

Tabla 1

Porcentaje de casos de diabetes

	Frecuencia	Porcentaje (%)
No diabetes	213703	84,24%
Diabetes	35346	13,93%
Prediabetes	4631	1,83%

Frecuencia de casos de diabetes y porcentaje sobre el total de la muestra, obtenidos de la encuesta BRFSS. Elaboración propia.

En cuanto al resto de datos de la fuente, a continuación, se muestra un esquema de su estructura, en las tablas 2-4:

Tabla 2*Variables de diagnóstico y estado fisiológico.*

Variable	Tipo de Dato	Rango	Descripción
Diabetes_012	Categórica (Ordinal)	0: No diabetes 1: Prediabetes 2: Diabetes	Variable Objetivo (Target). Diagnóstico del paciente.
HighBP	Binaria	0: No / 1: Sí	Presión arterial alta diagnosticada.
HighChol	Binaria	0: No / 1: Sí	Colesterol elevado diagnosticado.
CholCheck	Binaria	0: No / 1: Sí	Chequeo de colesterol en los últimos 5 años.
BMI	Numérica (Continua)	Reales (kg/m ²)	Índice de Masa Corporal.

Elaboración propia.

Tabla 3*Factores de riesgo y estilo de vida.*

Variable	Tipo de Dato	Codificación / Rango	Descripción Técnica
Smoker	Binaria	0: No / 1: Sí	Ha fumado al menos 100 cigarrillos en su vida.
Stroke	Binaria	0: No / 1: Sí	Historial de accidente cerebrovascular.
HeartDiseaseorAttack	Binaria	0: No / 1: Sí	Enfermedad coronaria o infarto previo.
PhysActivity	Binaria	0: No / 1: Sí	Actividad física en los últimos 30 días.
Fruits / Veggies	Binarias	0: <1 vez/día 1: >1 vez/día	Consumo diario de frutas y verduras.
HvyAlcoholConsump	Binaria	0: No / 1: Sí	Consumo elevado de alcohol (hombres >14, mujeres >7/semana).

Elaboración propia.

Tabla 4*Acceso a la salud, estado general y demografía.*

Variable	Tipo de Dato	Codificación / Rango	Descripción Técnica
----------	--------------	----------------------	---------------------

GenHlth	Categórica (Ordinal)	1 (Excelente) a 5 (Mala)	Percepción general de la salud.
MentHlth / PhysHlth	Numéricas (Discretas)	0 a 30 días	Días con salud mental/física deficiente (últimos 30 días).
DiffWalk	Binaria	0: No / 1: Sí	Dificultad severa para caminar o subir escaleras.
AnyHealthcare	Binaria	0: No / 1: Sí	Cobertura de atención médica o seguro de salud.
NoDocbcCost	Binaria	0: No / 1: Sí	Barrera económica para acudir al médico en el último año.
Sex	Binaria	0: Mujer / 1: Hombre	Sexo biológico del participante.
Age	Categórica (Ordinal)	1 (18-24) a 13 (>80)	Rango de edad estructurado en intervalos de 5 años.
Education	Categórica (Ordinal)	1 (Sin escolaridad) a 6 (Graduado)	Nivel educativo alcanzado.
Income	Categórica (Ordinal)	1 (<\$10k) a 8 (>\$75k)	Nivel de ingresos anuales del hogar.

Elaboración propia.

Como se pudo observar en la tabla 1, la variable objetivo original *Diabetes_012*, cuenta con una estructura multiclase, en la que la frecuencia de casos para la prediabetes apenas representaba una parte minoritaria del 1,8% de los datos.

Esta distribución generaba un problema grave de desbalanceo de clases, por lo cual se procedería durante el desarrollo del proyecto a la binarización estratégica de esta variable, pasando ahora denominarse *Diabetes_01* y agrupando las clases Diabetes y Prediabetes bajo una única categoría (1) y la categoría de control permaneciendo igual (No diabetes = 0).

4.2. Entorno y librerías

Para el desarrollo del proyecto y el modelado predictivo de los datos, se empleó **Databricks**, una plataforma de analítica de datos basada en la nube. La elección de este entorno, parte de la necesidad de disponer de un entorno amigable y que respondiese a la necesidad de gestionar un gran volumen de datos de manera eficiente, escalable y segura.

La resolución del proyecto tuvo lugar mediante **Databricks Notebooks** basados en **Python**, dado que el flujo de trabajo era fácilmente estructurable de manera modular y visual, permitiendo que la

integración de los datos fuese fluida y reproducible. Al generarse todos los notebooks dentro del mismo *workspace*, la integración de los diferentes elementos no suponía ningún reto añadido.

El lenguaje escogido fue *Python*, dado que resultaba el más familiar y mejor adaptado para muchas de las librerías empleadas en el proyecto. Haciendo un repaso breve sobre las mismas, se puede observar, que en general, las librerías utilizadas constituyen el estándar de la industria:

Para la estructuración y manipulación de los datos, se emplearon librerías como **Pandas** y **Numpy**. En visualizaciones y análisis gráfico de los datos, tanto **Matplotlib** como **Seaborn**, constituían la mejor opción para representar gráficos sencillos y editables sin incluir una complicación añadida. Y para el proceso de preprocesado de los datos, generación de los modelos de aprendizaje supervisado y la evaluación de estos, sin duda, **Scikit-learn** fue la opción elegida, debido a su integración con todas las anteriores, su trayectoria, y la infinidad de herramientas integradas en su ecosistema, que permiten realizar prácticamente cualquier proceso sin salir del mismo.

4.3. Preprocesamiento de datos

Para el preprocesamiento y preparación de los datos, se realizaría un eliminado de duplicados, seguido de algunas transformaciones en los datos para tratar los *outliers* que fueron apareciendo durante el proceso del análisis exploratorio.

Como los datos ya venían completos de serie, es decir, no contaban con valores faltantes o nulos, no fue necesario imputar o excluir valores por este motivo.

4.4. Algoritmos de Machine Learning

En la elección de los algoritmos de aprendizaje, se tuvo en cuenta que fuesen variados y que representasen diferentes espectros que fuesen desde lo sencillo a lo complejo y pasando por diferentes criterios de decisión para la separación de clases: un modelo lineal simple como la **Regresión Logística**, otro modelo basado en distancias (**KNN**⁴), dos basados en árboles de decisión (**Random Forest** siguiendo el concepto de **bagging**⁵ y **Gradient Boosting** siguiendo el enfoque del **boosting**⁶) y por último una **Red Neuronal** para ver si era capaz de encontrar relaciones que los anteriores no.

En aquellos modelos que contaban con una herramienta de balanceo de clases nativa, se aplicó el parámetro para tratar de optimizar los resultados para la clase objetivo (Diabetes), mientras que en aquellos que no lo incluían de forma nativa, primero se ejecutaron tal cual, y una vez se demostró que no eran tan efectivos como aquellos en los que se incluía el parámetro de balanceo, se buscó un método alternativo por medio de la **validación cruzada**, para tratar de encontrar los umbrales óptimos de

decisión en cada modelo, orientados a la obtención del mejor ratio de AUC-ROC – sensibilidad para nuestros modelos.

4.5. Métricas de evaluación

La evaluación del rendimiento de los modelos de aprendizaje automático no depende nunca de un único indicador estadístico, y habitualmente, y en función del objetivo que se tenga o el ámbito sobre el que se trabaje, se trata de maximizar un conjunto de indicadores que representan la fiabilidad de nuestro modelo en concreto.

En este proyecto, se tuvieron en cuenta una serie de métricas derivadas de la **matriz de confusión** (es la matriz que desglosa los resultados del modelo en cuatro categorías diferenciadas: *verdaderos positivos (VP)*, *verdaderos negativos (VN)*, *falsos positivos (FP)* y *falsos negativos (FN)*) de cada modelo:

- Exactitud (Accuracy)
- Precisión (Precision)
- Sensibilidad (Recall)
- Puntuación (F1 Score)

Concretamente para los sistemas de apoyo médico y en las herramientas de cribado de la salud pública, la importancia de priorizar un *recall* alto es crítica, puesto que identificar a los individuos del grupo con la patología, debería constituir siempre la máxima del modelo. El coste de un falso negativo (FN) es infinitamente superior al coste de un falso positivo (FP).

Clasificar a un individuo con diabetes como sano, podría suponer privarle de intervenciones tempranas, seguimiento adecuado, agravamiento de la enfermedad y complicaciones... Mientras que clasificar a un individuo sano como un sujeto de riesgo, tan solo conlleva un posible coste de tiempo y económico al tener que realizarle una revisión rutinaria o una prueba de confirmación para descartar la presencia de la enfermedad.

Adicionalmente, se incluye la métrica de AUC-ROC, la cual evalúa la capacidad de discriminación del modelo para todos los umbrales de decisión posibles. Constituye la métrica estándar de la bioestadística para medir la robustez general de un clasificador.

5. Resultados

A continuación, se sintetizará el proceso empleado para el desarrollo del proyecto y se presentarán los hallazgos obtenidos de la metodología aplicada.

Con el propósito de que la información sea lo más clara y trazable posible, los resultados seguirán una estructura secuencial equiparable a la que se empleó para el desarrollo del proyecto, desde la decisión de la fuente de datos y la inspección exploratoria de los mismos, hasta la optimización de los modelos obtenidos.

En las siguientes subsecciones, se presentará la procedencia del conjunto de datos, junto con su estructura y distribución de variables que la conforman.

5.1. Adquisición de fuentes de datos

Cómo se expuso en el apartado 4.1, los datos proceden de un dataset de Kaggle ligado al *Behavioral Risk Factor Surveillance System (BRFSS)* del Centro de Control y Prevención de Enfermedades de EE. UU. (CDC).

Entre los principales motivos en la elección de este conjunto de datos destacan tanto la relevancia y rigor de los datos (es una encuesta realizada de forma continua por un organismo oficial), como el interés personal por los mismos.

Como comentado, la fuente de datos es una versión extraída de Kaggle, la cual filtra y estructura el enorme estudio llevado a cabo por la BRFSS de 2015, facilitando un dataset limpio con 22 variables clave para el análisis de la enfermedad. Además, el dataset presenta un número de registros altamente elevado. Cuenta con más de 250.000 registros, lo cual permitía poner a prueba algoritmos más complejos como Random Forest o Gradient Boosting, sin caer en riesgos de sobre ajuste (overfitting).

El dataset contaba con variables simples, fáciles de comprender por el público ajeno a la medicina y eran auto reportadas por los participantes en la encuesta, lo cual suponía un reto interesante, ya que, de lograr alcanzar unos resultados decentes, podría suponer una forma de cribado altamente eficiente, barata y poco invasiva, a diferencia de las pruebas médicas generales habituales.

5.2. Descripción de la fuente de datos

El conjunto de datos presentaba una estructura limpia, sin valores faltantes, lo cual simplificaba el proceso del preprocesado de datos. Sin embargo, no convertía el proyecto en algo más sencillo,

únicamente simplificaba el proceso de imputación de valores faltantes que comúnmente se realiza sobre datos incompletos. Algunas de las principales técnicas empleadas durante este proceso serían:

- **Eliminación** → Se eliminarían filas completas si contienen al menos un valor nulo, lo cual solo tiene sentido cuando la muestra es muy grande y la eliminación de datos no supone una representación muy grande sobre el total. En algunos casos, se opta por eliminar columnas (variables) completas cuando el umbral de nulos para esa variable en concreto supone una gran proporción de los datos.
- **Imputación de medias** → Se remplazarían los valores nulos por algún valor estadístico calculado como la media (variables numéricas continuas y sin mucho outlier), la moda (como la media, pero para distribuciones más sesgadas) o la mediana (generalmente utilizada para variables categóricas).
- **Imputación avanzada** → Empleando modelos de aprendizaje automático basados en decisiones (Random Forest) o en distancias (K-Nearest Neighbors).

En este caso, ninguno de estos procedimientos fue aplicado en la realización del proyecto, sin embargo, es muy probable que alguno de ellos o una combinación de varios, fuese empleada la hora de cribar la fuente de datos en crudo obtenida de la encuesta.

Sobre la estructura de los datos, se puede observar una división entre la variable objetivo y variables de diagnóstico y estado fisiológico como se presentó anteriormente en la Tabla 2, un segundo conjunto de variables relacionadas con los factores de riesgo estilo de vida, presentadas en la Tabla 3 y, por último, una serie de variables relacionadas con el acceso a la salud y características demográficas, expuestas en la Tabla 4.

Si bien la limpieza de los datos supuso una facilidad la hora de la preparación de los datos, la distribución de la variable objetivo suponía más bien una complicación que tocaba atajar de alguna manera.

Figura 2

Distribución y frecuencia de la variable objetivo

	Frecuencia	Porcentaje (%)
Diabetes_012		
0.0	213703	84.241170
2.0	35346	13.933302
1.0	4631	1.825528

Elaboración propia a partir de datos de la encuesta BRFSS.

Como se puede observar en la Figura 2, la variable objetivo sufría un fuerte desbalanceo de clases, representando la clase 1 (Prediabetes), tan solo el 1,8% de los registros. Esto suponía un desafío técnico real y la utilización de técnicas de preprocesado avanzado y ajuste de pesos de clases para poder obtener modelos de aprendizaje que fuesen capaces de obtener resultados acordes a la realidad.

Con objeto de solucionar este problema y teniendo en cuenta que la prediabetes constituye un riesgo muy similar al de la propia enfermedad, con la salvedad de que en estas personas la condición es reversible, se optó por considerar a los pacientes prediabéticos como potenciales enfermos y así reducir el desbalanceo de clases y poder aplicar medidas preventivas sobre este grupo. Así, la nueva distribución de los datos era la recogida en la Figura 3.

Figura 3

Distribución variable objetivo post unificación de clases

	Frecuencia	Porcentaje (%)
Diabetes_01		
0	213703	84.24117
1	39977	15.75883

Elaboración propia a partir de datos de la encuesta BRFSS.

Con esta nueva variable objetivo, agrupada, y la eliminación de la anterior para evitar confusiones, se dio paso al proceso de Análisis Exploratorio de los Datos (EDA).


5.3. Análisis exploratorio de los datos (EDA)

Como primer paso del EDA, se decidió medir cómo las variables numéricas con un mayor rango de valores se comportaban frente a la variable objetivo. Esto, con la intención de descubrir su capacidad discriminativa antes si quiera de introducirlas en los modelos a desarrollar. La lógica detrás de la decisión radicaba en que si variables con rangos tan amplios diferían notoriamente entre el grupo con y sin diabetes, lo que se estaría confirmando es que existen ciertos patrones que dividen los grupos y de los cuales más adelante se podrían aprovechar los algoritmos de aprendizaje automático para lanzar sus predicciones.

Así, primeramente, se tomaron las variables ‘BMI’, ‘Age’ y ‘GenHlth’ para tratar de observar visualmente su comportamiento como se puede ver en la Figura 4.

Figura 4

Distribución frente a variable objetivo



Elaboración propia.

De aquí, se extrajo la conclusión de que todas las variables analizadas (BMI, Age y GenHlth) mostraban patrones claramente diferenciados para los diferentes grupos de la variable objetivo. En primer lugar, la variable que representa el Índice de Masa Corporal (BMI), mostraba registros más elevados en promedio en los individuos con la patología, esto no era para nada de extrañar, ya que como se pudo observar, uno de los principales factores de riesgo de la diabetes tipo II eran el sobrepeso y la obesidad.


Por otro lado, la variable que referencia a la edad también mostraba valores más elevados en promedio en el grupo diabético y algunos pequeños outliers en edades muy tempranas. Esto se debía a que otro de los principales factores de riesgo lo constituye la edad. Se calcula que a partir de los 35-45 años, el riesgo de sufrir diabetes sube drásticamente, en parte motivado por los cambios fisiológicos que sufre el cuerpo en este periodo, y agregado a la pérdida de masa muscular que trae consigo el envejecimiento. Esto fomenta cambios conductuales que pueden derivar en comportamientos más sedentarios o peores hábitos alimentarios.

Por último, los individuos con diabetes tendían a autoperibirse en peor estado de salud general que los individuos sanos, precisamente, por todo lo comentado anteriormente y las propias consecuencias de la enfermedad. No obstante, esta variable también podría emplearse como predictora, puesto que en el caso de la diabetes de tipo II, la enfermedad se desarrolla en el tiempo debido a una serie de malos hábitos y conductas, que pueden autoperibirse como peor condición de salud general antes incluso de desarrollar la enfermedad.

Adicionalmente se trabajó sobre las variables de salud mental y salud física, pero arrojaron resultados similares a los mostrados en salud general. Obsérvese la Figura 5.

Figura 5

Salud física y mental frente a la variable objetivo



Elaboración propia.

Para las variables de tipo binario (0,1), se tomó un enfoque ligeramente diferente. Se decidió realizar un análisis bivariado, cruzando estas variables frente a la variable objetivo. De este modo se obtuvo el porcentaje de casos por grupo para cada variable. Aquí la idea consistía en analizar si las variables presentaban distribuciones diferenciables entre individuos sanos y enfermos. Así, por ejemplo, si los individuos del grupo sano mostraban en un 37% de los casos una frecuencia cardíaca elevada, y los del grupo objetivo representaban el 73% de los casos, la información que podía extraerse es que, los individuos diabéticos suelen tener frecuencias cardíacas más elevadas (véase la Tabla 5).

Tabla 5*Análisis bivariado frente a variable objetivo*

Variable	Sin Diabetes (0)	Con Diabetes / Riesgo (1)	Diferencia (%)
HighBP	37,11%	73,83%	36,72%
HighChol	37,92%	66,44%	28,52%
CholCheck	95,71%	99,24%	3,53%
Smoker	42,97%	51,53%	8,56%
Stroke	3,16%	8,84%	5,68%
HeartDiseaseorAttack	7,18%	21,37%	14,19%
PhysActivity	77,91%	63,61%	-14,30%
Fruits	64,30%	58,74%	-5,56%
Veggies	82,14%	75,79%	-6,35%
HvyAlcoholConsump	6,18%	2,60%	-3,58%
AnyHealthcare	94,97%	95,81%	0,84%
NoDocbcCost	7,96%	10,86%	2,90%
DiffWalk	13,23%	36,04%	22,81%
Sex	43,40%	47,43%	4,03%


Elaboración propia

Algunas de las conclusiones obtenidas de este análisis son la aparente relación que guardan variables como HighBP, HighChol, PhysActivity y DiffWalk con la variable objetivo. Y cómo la variable que representa un consumo elevado de alcohol (HvyAlcoholConsump) muestra un comportamiento extraño, pareciera que los sujetos con un fuerte consumo de alcohol padeciesen menos casos de diabetes. Esto es un claro ejemplo de que correlación no implica causalidad.

Por último y para cerrar el proceso de análisis exploratorio, se realizó una matriz de correlaciones en forma de mapa de calor para visualizar las correlaciones de las variables con la variable objetivo y entre sí, y ser capaces de detectar posibles casos de multicolinealidad⁷ en el caso de que varias variables compartiesen un grado elevado de relación entre sí, y pudiesen explicarse únicamente con una de ellas.

Figura 6

Matriz de correlaciones de las variables predictoras



Elaboración propia

Del análisis de las correlaciones, se concluyó que, si bien algunas variables compartían cierta relación, en ningún caso era suficiente como para adoptar medidas y dejar de depender de alguna de ellas. Por otro lado, se vio que variables como la salud general, el índice de masa corporal o el ritmo cardíaco elevado, seguían mostrándose como aquellas que más relación guardaban con la variable objetivo.

5.4. Preprocesado de datos


Llegando a este punto, se retomó el tema de los duplicados. La fuente de datos contaba con un total de 23.899 duplicados, un número no menor, pero perfectamente posible al ser un problema recurrente en este tipo de encuestas (mucha gente responde exactamente igual a preguntas

categorías). La decisión que se tomó fue la de eliminarlos de la ecuación por dos motivos principales: el dataset y la proporción de clases se mantenían relativamente invariables, y por otro lado existía el riesgo de que los duplicados aportasen patrones de repetición inexistentes a los algoritmos de aprendizaje, o incluso peor, que al hacer la partición de datos en train y test, los duplicados se colasen a cada lado de la partición y supusieran un problema de data leakage⁸.

Otro de los puntos clave a tratar durante este apartado fueron los outliers. Durante el EDA, se observó que variables como BMI (Índice de Masa Corporal) contaban con valores atípicos por encima de los rangos habituales.

Figura 7

Distribución del índice de masa corporal en pacientes con y sin diabetes.



Elaboración propia

Como se muestra en la Figura 7, en el gráfico no existían valores imposibles, sin embargo, los grupos contaban con una gran cola de valores atípicos. Estudiando un poco el caso, se pudo ver que según datos extraídos del artículo médico “High body mass index is an important risk factor for the development of type 2 diabetes”, el riesgo de diabetes ocasionado por sobrepeso incrementaba de manera exponencial en pacientes con un BMI superior a 25-27,5, sin embargo, el riesgo no crecía de

manera exponencial a partir de este umbral. Esto, sumado a la rareza de los casos por encima de 60, fue una de las principales razones que sustentaron la decisión de windsorizar⁹ los datos, para evitar que valores extremadamente atípicos pudiesen ser vistos por los algoritmos como datos de mayor peso, algo que teóricamente se descartó, al constatar que el riesgo no crecía de manera exponencial con el índice de sobrepeso.

El cambio apenas se notó puesto que únicamente afectó al 0,3% de los datos, los cuales no fueron eliminados, sino que se les imputó un valor máximo de 60.


5.5. Selección de variables

Durante el EDA, se realizó una matriz de correlaciones para comprobar la relación directa que guardaban las variables predictoras con la variable objetivo. Adicionalmente, también se habían realizado análisis bivariados para las variables binarias y una serie de análisis gráficos para intuir si existía relación entre las variables numéricas de mayor rango y la variable objetivo. No obstante, se decidió realizar un último análisis más avanzado, con el fin de descubrir posibles relaciones ocultas, no lineales o fruto de una combinación de variables, que se hubiesen podido pasar por alto previamente.

Así lo que se decidió, fue implementar un algoritmo de Random Forest, al cual se le incluyó el parámetro nativo **class_weight='balanced'** para dar mayor prioridad a los aciertos sobre la clase minoritaria. El objetivo de este algoritmo consistió en obtener una lista de variables ordenadas de mayor a menor importancia considerada por el modelo, las cuales volverían a ser comparadas con las que previamente se habían obtenido, con el objetivo de tomar una decisión final a la hora de incluir o eliminar variables en los modelos (véase la Figura 8 con los resultados).

Figura 8

Importancia de las variables predictoras – Random Forest



Elaboración propia

Se puede observar cómo variables como **‘BMI’**, **‘Age’** o **‘GenHlth’** siguen apareciendo en los primeros puestos del ranking de importancia, manteniendo así la tendencia que se venía observando previamente durante los análisis acometidos en el EDA.


Otras variables como **‘Income’**, parecen ganar peso en este análisis, esto puede tener su explicación en que los árboles de decisión estén encontrando relaciones no lineales con la variable objetivo. Por poner un ejemplo, generalmente unos bajos ingresos suelen ir acompañados de unos peores hábitos alimenticios, difícil acceso a la salud mental, etc. Es por eso por lo que en este tipo de análisis avanzado

con Random Forest, pueden aparecer variables con más peso de lo que se había podido observar previamente.

Llegados a este punto, y con fines didácticos, se decidió aplicar un último estadístico. Con el fin de encontrar más relaciones ocultas, se aplicó un algoritmo de información mutua para descubrir relaciones individuales, tanto lineales como lineales, en las variables predictoras con la variable objetivo.

Figura 9

Importancia de las variables predictoras – Información mutua



Elaboración propia

Es curioso como analizando este nuevo algoritmo (Figura 9), la clasificación cambia radicalmente y variables como 'AnyHealthcare' y 'ColCheck', que en Random Forest aparecían en los últimos

puestos, aquí muestran mucha mayor relevancia, lo cual indicaba que quizás tenían más peso del que a priori se podía pensar. Sin embargo, a lo largo de todos los análisis, aparecieron una serie de variables que continuamente mostraban unos resultados de relación bastante pobres. De este modo, y siguiendo el principio de la **Navaja de Ockham**⁹, se decidió que estas variables que consistentemente mostraban una relación débil con la variable objetivo ('**Stroke**', '**HvyAlcoholConsump**' y '**NoDocbcCost**') no tenía sentido mantenerlas en los datos que se les pasaría a los modelos, puesto que, podrían suponer un ruido extra a la hora de establecer relaciones y generar predicciones.

5.6. Partición en Train y Test

Para la partición de los datos en train y test se tuvieron en cuenta 2 conceptos:

- Primeramente, se optó por una división clásica 80/20. Históricamente se tiende a seleccionar el 80% de los datos de la muestra como datos de train, este número no es algo al azar, sino que, generalmente y siguiendo el Principio de Pareto, se entiende que con este volumen de datos se suele capturar la gran mayoría de la señal útil del problema, mientras que dejar el 20% restante como datos de test, mantiene una muestra lo suficientemente grande, no conocida por los modelos, como para que las métricas de evaluación sean lo más fieles posible y unos pocos errores o aciertos fortuitos no distorsionen el resultado.
- Adicionalmente, otra de las consideraciones que se tuvo en cuenta fue la inclusión del parámetro **stratify=y**, para asegurar una correcta proporción de las clases y no desbalancear las particiones por error de manera aleatoria. Esta es una práctica habitual en conjuntos de datos que sufren de un fuerte desbalanceo de clases de base, y así, se evita que, al realizar la partición, de manera totalmente aleatoria caigan una gran cantidad de datos de uno de los grupos en alguno de los lados y no se tenga suficiente información en los datos de train para predecir estos.

Así, una vez habiéndose asegurado que los conjuntos mantenían la misma proporción que el original, se procedió con el siguiente paso, el escalado de variables.

Como bien se sabe, a la hora de trabajar con datos con escalas diferentes, es importante escalar los datos a un mismo nivel, para que los algoritmos no tiendan a darle mayor peso a variables con mayor rango, a menos que estas por algún motivo pudieran tenerlo. No fue el caso en este proyecto, por lo que la decisión fue la de aplicar un escalador (en este caso **StandardScaler**) sobre las variables no

binarias en train y posteriormente utilizar estos mismos valores para escalar los datos en test. Esta práctica es habitualmente empleada a la hora de escalar datos para machine learning, dado que así se evitan problemas de data leakage.

Realizar el escalado en train y usar los valores obtenidos en test asegura que el modelo trabaje con los datos “conocidos” y no se introduzca información “privilegiada” del conjunto de prueba (que a priori no debería ser conocida) para la preparación de los modelos. La principal consecuencia sería la obtención de métricas extremadamente optimistas durante las pruebas, que posteriormente durante la fase de producción del modelo fallarían estrepitosamente, al haberse ajustado de manera artificial a los resultados que se esperaba obtener.

Figura 10

Comprobación de medias tras escalar

```
Comprobación - medias en train tras escalar
BMI          -0.0
GenHlth      -0.0
MentHlth      0.0
PhysHlth     -0.0
Age           0.0
Education    -0.0
Income        0.0
dtype: float64

Comprobación - medias en test tras escalar
BMI          -0.008
GenHlth      -0.008
MentHlth      0.010
PhysHlth     -0.009
Age           -0.010
Education      0.017
Income        0.011
dtype: float64
```

Elaboración propia

Si el proceso se ha realizado correctamente, se deberían obtener medias en train iguales a 0, mientras que, para el conjunto de test, los valores deberían ser cercanos a 0, puesto que, si la división se hizo de forma aleatoria y equivalente, los datos de train y test serán similares, pero nunca iguales. Al aplicar la siguiente fórmula:

$$Z_{\text{test}} = \frac{x_{\text{test}} - \mu_{\text{train}}}{\sigma_{\text{train}}}$$

y restar valores casi idénticos $\mu_{\text{test}} - \mu_{\text{train}}$ el resultado será cercano a 0, pero nunca exacto.

Como se puede observar en la Figura 10, la escalación se realizó correctamente y los datos ya se encontraban dispuestos para comenzar con la aplicación de los diferentes algoritmos de aprendizaje automático.

5.7. Aplicación de modelos de aprendizaje automático

Cómo se comentó anteriormente, se eligieron 5 modelos para la realización del proyecto:

- Un modelo base, en este caso una **Regresión Logística**.
- Un modelo basado en distancias como **K-Nearest Neighbors**.
- 2 modelos basados en árboles de decisión: **Random Forest** y **Gradient Boosting**.
- Y un modelo de **Red Neuronal Simple** para buscar relaciones que hubieran podido quedar ocultas en los anteriores.


El primer paso consistió, por tanto, en importar los datos de train y test, que previamente habían sido transformados en .csv para facilitar su inmutabilidad y poder llamarlos consecutivamente para cada modelo y así facilitar que siempre se tomaran los mismos.

Como segundo paso y con el fin de simplificar la tarea de cálculo y reporte de los resultados obtenidos por cada modelo (manteniendo siempre el mismo formato y aplicando las mismas métricas), se optó por construir una función que reportase los datos de cada modelo, en el mismo formato, independientemente de cuál se estuviese ejecutando.

Para tratar de resumir los pasos de cálculo empleados en la función anteriormente mencionada, se incluye un diagrama del flujo en la Figura 11.

Figura 11

Diagrama de flujo – Función evaluar modelos



Elaboración propia empleando herramientas de IA

Durante este primer despliegue de los modelos, el flujo de trabajo se limitó a su ejecución mediante la función que previamente se ha comprobado. Para cada modelo se reportó una matriz de contingencia de los resultados y adicionalmente se calcularon las métricas de *Accuracy*, *Precision*, *Recall*, *F1* y *AUC-ROC*, aunque en este caso y para el contexto de la diabetes, se le daría importancia crítica a la *Accuracy* (Sensibilidad) y la métrica *AUC-ROC* (capacidad global de discriminación del modelo).

Se recuerda que, en contextos clínicos, el coste de los Falsos Negativos (decirle a un paciente enfermo que está sano) se penaliza de forma mucho más grave que un Falso Positivo (tener que realizar pruebas adicionales a un paciente sano para descartar que tenga la enfermedad). Dicho esto, se presenta a continuación en la Figura 12 los resultados obtenidos tras el primer despliegue:

Figura 12

Primera comparativa métricas modelos


	accuracy	precision	recall	f1	auc_roc
Gradient Boosting	0.7101	0.3457	0.7603	0.4753	0.8089
Regresión Logística	0.7180	0.3497	0.7374	0.4744	0.8004
Red Neuronal (MLP)	0.8386	0.5968	0.2005	0.3001	0.8063
KNN	0.8296	0.5174	0.1913	0.2793	0.7663
Random Forest	0.8235	0.4716	0.1853	0.2661	0.7692

Elaboración propia

Se puede observar que el mejor modelo sobre el papel fue el *Gradient Boosting*, con un *AUC-ROC* de 0,809 y un *recall* del 76%, se impuso por poco sobre la *Regresión Logística*, que partía como nuestra modelo base y más sencillo, pero que demostró buenos resultados debido a su parámetro nativo de balanceo de clases `class_weight='balanced'`. En capacidad discriminatoria total, la *Red Neuronal* se comportó bastante bien, sin embargo, sus resultados no eran demasiado aprovechables al igual que los de los modelos de *KNN* y *Random Forest*, puesto que presentaban métricas de sensibilidad bastante mediocres para un estudio como el que se planteaba.

Figura 13

Comparativa de curvas ROC



Elaboración propia


En este apartado, se concluyó que, si bien todos los modelos mostraban una capacidad para ordenar el riesgo de forma bastante decente, tan solo dos de ellos cumplían con el objetivo de mantener una sensibilidad lo suficientemente alta como para tomar sus resultados en cuenta. Es por esto por lo que, en el siguiente apartado, se trata de ajustar los modelos que peor se comportaron y tratar de amoldarlos a las métricas que se quieren maximizar para el proyecto de cribado de pacientes diabéticos.

5.8. Evaluación y validación de modelos de aprendizaje automático

Del mismo modo que se preparó la función *evaluar_modelo*, se construye una función para encontrar el umbral óptimo de cada modelo que presentó una sensibilidad baja (KNN, Random Forest y MLP), representada en la Figura 14.

Figura 14

Diagrama de flujo – Función umbral_optimo



Elaboración propia empleando herramientas de IA

Aquí es interesante destacar que el umbral que se pretende lograr es aquel que maximiza el F1 score y no el recall. Esto tiene su explicación en que, si se tratase de maximizar el recall, el umbral óptimo se situaría cercano a 0, lo cual produciría que se tendiese a clasificar a todos los individuos como personas con diabetes, generando un gran número de falsos positivos. A continuación, se muestra la fórmula de cálculo para el F1:

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Al maximizar el F1 Score, la función lo que trata de encontrar es el equilibrio entre el recall y la precisión, es decir, manteniendo una buena tasa de detección de positivos reales, sin saturar las predicciones de falsos positivos. En la figura 15 se muestran los umbrales óptimos obtenidos para cada modelo.

Figura 15

Umbrales óptimos por modelo

Resultdos	
KNN	0.2667
MLP	0.2610
Random Forest	0.2297

Elaboración propia

5.9. Comparativa de resultados

Para la comparativa final se realizó una tabla con las métricas obtenidas en cada modelo (incluyendo aquellos en los que se maximizó el umbral de decisión), ordenadas por sensibilidad y dónde se destacaba también el AUC-ROC de cada uno de ellos, con el fin de, a resultados iguales o similares, decantarse por esta métrica.

Queda así recogido en la Figura 16:

Figura 16

Comparativa de métricas finales por modelo

	accuracy	precision	recall	f1	auc_roc
Gradient Boosting	0.7101	0.3457	0.7603	0.4753	0.8089
Regresión Logística	0.7180	0.3497	0.7374	0.4744	0.8004
MLP (Umbral Óptimo)	0.7758	0.4035	0.6242	0.4902	0.8063
Random Forest (Umbral Óptimo)	0.7412	0.3565	0.6198	0.4526	0.7692
KNN (Umbral Óptimo)	0.7446	0.3602	0.6172	0.4549	0.7663
Red Neuronal (MLP)	0.8386	0.5968	0.2005	0.3001	0.8063
KNN	0.8296	0.5174	0.1913	0.2793	0.7663
Random Forest	0.8235	0.4716	0.1853	0.2661	0.7692

Elaboración propia


Se puede observar que, si bien los modelos ajustados mejoraron su *recall* a costa de sacrificar *accuracy*, aún así quedaron lejos de los resultados obtenidos en regresión logística, y sobre todo de aquellos que obtuvo el gradient boosting. Al modificar los umbrales de decisión, lo que se consigue es que la frontera de decisión de los algoritmos suba o baje en función de para qué se esté maximizando, y de este modo, la probabilidad de suceso a partir de la cual se toma una decisión cambia.

En la librería Scikit-Learn, los umbrales de decisión vienen por defecto ajustados a 0,5, este valor solo sería útil en el caso en que las clases a predecir se encontrasen perfectamente balanceadas, puesto que, las probabilidades serían idénticas. Sin embargo, en fuentes de datos como la que se empleó en este proyecto, los datos cuentan con un fuerte desbalanceo de clases, y la clase minoritaria representa un número de casos acorde a la realidad, siendo muy inferior a la que contiene a los individuos sanos. En este tipo de casos, el umbral óptimo siempre se situará por debajo de la igualdad, siendo en estos casos cercano a 0,25 como se pudo comprobar anteriormente en la Figura 15.

Por otro lado, si se observa con atención, destaca un dato curioso, todos los modelos ajustados sufrieron cambios en sus métricas de valoración, salvo en una de ellas, el AUC-ROC. Este hecho se explica, ya que, al modificar los umbrales de decisión, tan solo se altera la forma en que los modelos distribuyen sus predicciones, sin embargo, su capacidad discriminadora global permanece inmutable, como puede observarse en la Figura 17, dónde las gráficas de los modelos originales y su par ajustado se solapan unas con otras y resulta en un gráfico exactamente igual que el que se mostró en la Figura 13.

Figura 17

Comparativa final Curvas ROC



Elaboración propia

6. Conclusiones

El presente proyecto que se ha presentado como Trabajo de Fin de Máster, ha tenido como objetivo plantear, desarrollar y evaluar diferentes sistemas de medición del riesgo de diabetes mediante algoritmos de aprendizaje automático, tomando siempre como referencia datos basados en la encuesta poblacional de BRFSS de 2015. Tras los resultados obtenidos, se ha constatado que es posible obtener modelos con la suficiente capacidad discriminativa como para ser empleados como herramienta de ayuda en los cribados médicos poblacionales para enfermedades como la diabetes. Si bien los resultados obtenidos se sitúan lejos de la perfección, la herramienta bien podría ser utilizada como primera barrera de cribado con el fin de reducir los costes en la atención primaria.

Dejando a un lado el resultado perfecto, gracias al proceso didáctico de implantación de diversos modelos de aprendizaje automático, se pudieron extraer ciertas conclusiones metodológicas. Entre ellas, se demostró que los cinco modelos empleados, bien podían clasificar el riesgo de manera similar, alcanzando capacidades discriminatorias similares (0,76-0,81) bajo su métrica AUC-ROC. Sin embargo, dependiendo de sobre que clase se quisiera enfocar el problema, algunos de ellos funcionaron de manera estándar mejor que otros. Como se pudo observar, los modelos de KNN, Random Forest o MLP, presentaban sensibilidades realmente bajas, en parte, debido a la falta de mecanismos nativos de compensación al desbalanceo de clases como los que sí podían tener la Regresión Logística o el Gradient Boosting (`class_weight= 'balanced'`). Este hecho resultó fácilmente ajustable una vez detectado el problema, actuando sobre los umbrales de decisión de todos estos modelos. De esta forma, se cerraban todos los modelos con una capacidad predictiva para la clase minoritaria decente a buena (62% -76%).

Tras la comparativa final de resultados, se optó por seleccionar el modelo de Gradient Boosting con 19 variables predictoras, el cual fue el que mejor se comportó, arrojando un AUC-ROC de 0,81 y una sensibilidad (accuracy) total del 0,76. Su precisión F1 se situó en 0,475, algo que se asumió como parte del problema del desbalanceo de clases, pero que se aceptó como válida al ser un problema común en este tipo de conjuntos de datos. La máxima fue la de encontrar aquel modelo que permitiese realizar cribados preliminares dónde la prioridad fuese detectar el mayor número de casos de riesgo, aún a costa de introducir falsos positivos en la ecuación.

A pesar de los resultados obtenidos, deben señalarse varias limitaciones encontradas durante el proyecto. Al analizarse datos obtenidos de encuestas con variables autodeclaradas se tiende a encontrar sesgos de memoria o deseabilidad social en ellos. Por una parte, el sesgo de memoria consiste en individuos que proporcionan respuestas alejadas de la realidad, simplemente porque no recuerdan con precisión los datos que se les preguntan, sin embargo, proporcionan una respuesta, la cual, si ocurre

en exceso, puede condicionar el resultado de los modelos. Por otro lado, al hablar de sesgo de deseabilidad social, es relativamente común que, en este tipo de encuestas, los encuestados contesten a ciertas preguntas con las respuestas que consideran socialmente aceptables y no con la realidad. Esto, nuevamente, representa una inexactitud en los datos, la cual induce comportamientos alejados de la realidad en los modelos, en la medida en que este tipo de respuestas se produzcan de manera reiterada. Se convierten así en las principales causas de que los modelos contengan más ruido del deseado y que sus predicciones se queden en niveles buenos, pero no excelentes, como podría darse a través de datos empíricos como los obtenidos en unas pruebas o análisis.

7. Referencias bibliográficas

1. Instituto Nacional de la Diabetes y las Enfermedades Digestivas y Renales. (s. f.). *¿Qué es la diabetes?* National Institutes of Health. <https://www.niddk.nih.gov/health-information/informacion-de-la-salud/diabetes/informacion-general/que-es>
2. Teboul, A. (2021). Diabetes Health Indicators Dataset. Kaggle. <https://www.kaggle.com/datasets/alexteboul/diabetes-health-indicators-dataset>
3. Numiqo. (s. f.). *Multicolinealidad - Explicación sencilla*. Recuperado el 18 de septiembre de 2026, de [Multicolinealidad - Explicación sencilla | numiqo](#)
4. Sawtooth Software. (25 de marzo de 2025). *Data cleaning in survey research*. Sawtooth Software Blog. <https://sawtoothsoftware.com/resources/blog/posts/data-cleaning-in-survey-research>
5. IBM. (14 de enero de 2026). *¿Qué es la fuga de datos?* IBM Think. <https://www.ibm.com/es-es/think/topics/data-leakage>
6. Muñoz, H. (3 de julio de 2025). *Datos atípicos (outliers) en machine learning: impacto, detección y aplicaciones en detección de fraude*. DiseNet: Blog de Tecnología, Datos, Machine Learning y BigData. <https://disenet.com/datos-atipicos-outliers-en-machine-learning-impacto-deteccion-y-aplicaciones-en-deteccion-de-fraude/>
7. UCSF Biostatistics Core. (s. f.). *Obesity*. Department of Surgery, University of California, San Francisco. Recuperado el 18 de septiembre de 2026, de <https://surgerybiostat.ucsf.edu/condition/obesity>
8. Sanada H, Yokokawa H, Yoneda M, Yatabe J, Sasaki Yatabe M, Williams SM, Felder RA, Jose PA. High body mass index is an important risk factor for the development of type 2 diabetes. *Intern Med*. 2012;51(14):1821-6. doi: 10.2169/internalmedicine.51.7410. Epub 2012 Jul 15. PMID: 22821094; PMCID: PMC3540801.
9. ATLAS.ti. (s. f.). Sesgo de deseabilidad social: Definición y mitigación. <https://atlasti.com/esSesgo-de-deseabilidad-social-Definición-y-mitigación-ATLAS.ti>
10. Appinio. (s. f.). Sesgos en investigación, cómo evitarlos y ejemplos. Appinio Blog. [Sesgos en investigación, cómo evitarlos y ejemplos | Appinio Blog](#)
11. Rogozhnikov, A. (s. f.). Gradient Boosting Interactive Playground [Aplicación web interactiva]. [Gradient Boosting Interactive Playground](#)
12. Sanz Rodríguez, E. (2020). *‘Optimización bayesiana en técnicas de aprendizaje automático “machine learning” clásicas: redes neuronales y XGBoost y su aplicación como modelos predictores de diabetes en pacientes ecuatorianos’*. Tesis de fin de Doctorado, Universitat Politècnica de

Catalunya]. UPCommons. <https://upcommons.upc.edu/server/api/core/bitstreams/2683a582-2ba7-4acd-b8bb-39c282e1a0f4/content>

8. Notas

¹ La **BRFSS** es la encuesta telefónica sobre salud más grande del mundo. La coordinan los CDC (*Centers for Disease Control and Prevention*) de EE. UU. Su propósito es recopilar datos sobre comportamientos de riesgo para la salud y condiciones médicas crónicas.

² La **binarización** consiste en transformar una variable en una variable dicotómica (0 o 1) en función de un umbral o condición dada.

³ La curva **ROC** es un gráfico que permite evaluar y comparar la capacidad predictiva de un modelo de clasificación a medida que se modifica su umbral de decisión.

⁴ **KNN** es la abreviatura empleada para los algoritmos de aprendizaje supervisado basados en clasificación, conocidos como K-Nearest Neighbors (K vecinos más cercanos).

⁵ El **bagging** es una técnica de aprendizaje que combina las predicciones de múltiples submodelos individuales para construir un modelo final más robusto y con menor propensión al sobreajuste.

⁶ Denominamos **boosting** a la técnica de aprendizaje que construye modelos secuenciales que aprenden del anterior, con el objetivo de convertir clasificadores muy sencillos, en uno robusto y muy preciso.

⁷ Según Numiqo (s.f.) “En un análisis de regresión, la **multicolinealidad** se produce cuando dos o más variables predictoras (variables independientes) muestran una alta correlación. Esto puede hacer que los coeficientes de regresión sean inestables y dejen de ser interpretables.”

⁸ De acuerdo con IBM (2026) “La **fuga de datos** se refiere a la introducción indebida de información ajena al conjunto de datos de entrenamiento en el modelo durante su desarrollo, lo que puede dar lugar a resultados demasiado optimistas y engañosos”

⁹ El principio de la **Navaja de Ockham** establece que ante dos o más explicaciones para un mismo fenómeno, la explicación más sencilla o aquella que supone el menor número de supuestos no probados es generalmente la mejor o más correcta.

9. Anexo

Repositorio de GitHub con los documentos anexos del TFM.

https://github.com/Adriibv/TFM_Adrian_Benito